

ĐỀ CƯƠNG ÔN TẬP HỌC MÁY

1 Lí thuyết

Câu 1. Khái niệm Overfitting trong học máy và tác động của nó đến hiệu suất mô hình. Nêu phương pháp giảm thiểu Overfitting và cách chúng hoạt động.

Đáp án:

- **Khái niệm:** Overfitting là hiện tượng mô hình quá khớp với dữ liệu training. Việc quá khớp này có thể dẫn đến việc mô hình dự đoán nhầm nhiễu (noise), từ đó mô hình sẽ không còn tốt trên tập test.
- **Phương pháp giảm thiểu:**
 - **Giảm độ phức tạp mô hình:** Giảm bậc của phương trình.
 - **Validation:** Thêm một tập valid để đánh giá sau khi train, giúp điều chỉnh mô hình sao cho cả train error và test error đều nhỏ.
 - **Cross-Validation:** Chia tập train thành k tập con. Mỗi lần thử, 1 tập con làm validation set, $k - 1$ tập còn lại làm training set. Hiệu suất cuối cùng tính bằng trung bình của k lần đánh giá.
 - **Regularization:** Thêm L_1, L_2 norm vào hàm loss để làm phần tử “phạt” mô hình.
 - **Dropout (Trong Neural Network):** Tắt ngẫu nhiên một số lượng neuron trong quá trình huấn luyện.

Câu 2. Khái niệm Underfitting trong học máy là gì và tác động của nó đến hiệu suất mô hình. Nêu phương pháp giảm underfitting và cách chúng hoạt động.

Đáp án:

- **Khái niệm:** Underfitting là hiện tượng mô hình quá đơn giản so với dữ liệu training, dẫn tới sai số cao trên mọi tập dữ liệu và thất bại trong việc xấp xỉ dữ liệu.
- **Phương pháp giảm thiểu:**
 - **Tăng độ phức tạp mô hình:** Tăng bậc của mô hình hoặc bổ sung thêm đặc trưng (features).
 - **Giảm cơ chế kiểm soát:** Giảm tham số phạt trong các mô hình sử dụng L_1, L_2 norm.
 - **Giảm số lượng lân cận (K):** Đối với mô hình sử dụng KNN.

Câu 3. Giải thích vai trò của hàm kích hoạt Sigmoid trong bài toán hồi quy logistic. Tại sao hàm sigmoid lại phù hợp để giải quyết bài toán phân loại nhị phân.

Đáp án:

- **Vai trò:** Trong Logistic Regression, mục tiêu là dự đoán nhãn nhị phân $y \in \{0, 1\}$. Cốt lõi của model là tổ hợp tuyến tính có đầu ra từ $-\infty$ đến $+\infty$. Hàm Sigmoid giúp ép các giá trị này về khoảng $(0, 1)$.
- **Lý do phù hợp:**
 - **Khớp với phân phối Bernoulli:** Phân phối nhị phân tuân theo phân phối Bernoulli, hàm Sigmoid đưa giá trị về xác suất trong khoảng $(0, 1)$.
 - **Độ tin cậy và ranh giới quyết định:** Khi $z \rightarrow +\infty \Rightarrow \text{sigmoid} \rightarrow 1$; khi $z \rightarrow -\infty \Rightarrow \text{sigmoid} \rightarrow 0$; tại $z = 0 \Rightarrow \text{sigmoid} = 0.5$.
 - **Toán học:** Đạo hàm đơn giản cho Gradient Descent và đảm bảo hàm mất mát lồi.

Câu 4. Phân biệt tác động của hai kỹ thuật chuẩn hóa: Min-Max scaling và Standardization lên phân phối của dữ liệu. Kỹ thuật nào nhạy cảm hơn khi dữ liệu có chứa ngoại lai (outliers)?

Đáp án:

- **Min-Max Scaling:** Ép dữ liệu vào khoảng giới hạn tĩnh, thường là $[0, 1]$ hoặc $[-1, 1]$.

$$x'_i = \frac{x_i - \min(x)}{\max(x) - \min(x)}$$

- **Standardization:** Đưa dữ liệu về dạng phân phối chuẩn với $\text{mean} = 0$ và $\text{variance} = 1$. Không giới hạn biên độ tối đa, tối thiểu.

$$x'_i = \frac{x_i - \text{mean}}{\sigma}$$

- **So sánh:** Min-Max Scaling nhạy cảm với outliers hơn vì nó phụ thuộc trực tiếp vào giá trị min và max. Các dữ liệu có thể bị bóp (squashed) nếu có outlier cực lớn hoặc cực nhỏ.

Câu 5. So sánh cách phản ứng với các điểm dữ liệu ngoại lai (outliers) của MSE và MAE. Nếu tập dữ liệu hồi quy có các điểm outliers, bạn sẽ ưu tiên sử dụng hàm nào? Tại sao?

Đáp án:

- **MSE (Mean Squared Error):** Tính trung bình bình phương sai số.

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- **MAE (Mean Absolute Error):** Tính trung bình giá trị tuyệt đối sai số.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- **Lựa chọn:** Ưu tiên chọn **MAE** vì tính kháng nhiễu (Robustness). Trong MSE, khoảng cách của outliers sẽ bị bình phương khiến sai số phình to, làm mô hình bị lệch hướng theo outliers. MSE thường giả định nhiễu tuân theo phân phối Gauss, không phù hợp khi có outliers.

Câu 6. Điểm khác biệt lớn nhất về tác động lên trọng số w giữa hồi quy LASSO (L_1) và hồi quy Ridge (L_2) là gì? Trường hợp tập dữ liệu có nhiều đặc trưng không quan trọng nên dùng mô hình nào?

Đáp án:

- **Lasso (L_1):** Sử dụng hàm phạt $\lambda\|w\|_1$. Lasso tạo ra tính thưa (*sparsity*) bằng cách ép một số trọng số về đúng bằng 0.
- **Ridge (L_2):** Sử dụng hàm phạt $\lambda\|w\|_2^2$. Ridge kiểm soát độ lớn bằng cách thu nhỏ trọng số về gần bằng 0 nhưng hiếm khi bằng 0.
- **Lựa chọn:** Nên dùng **Lasso** vì tính chất lựa chọn đặc trưng (*feature selection*), giúp loại bỏ các đặc trưng không quan trọng.

Câu 7. Giải thích khái niệm Cross-Validation, mô tả các bước thực hiện của phương pháp K-Fold Cross Validation.

Đáp án:

- **Khái niệm:** Là kỹ thuật đánh giá mô hình bằng cách chia nhỏ dữ liệu thành nhiều phần, huấn luyện và kiểm tra nhiều lần trên các phần khác nhau.
- **Các bước K-Fold:**
 1. Chia dữ liệu thành K phần bằng nhau.
 2. Lặp lại K lần: Tại vòng lặp thứ k , lấy tập con k làm validation set, $K - 1$ phần còn lại làm training set.
 3. Tính sai số trên tập xác thực của mỗi vòng lặp.
 4. Sai số cuối cùng là trung bình cộng của K lần đánh giá.
- **Ưu điểm:** Tránh lãng phí dữ liệu và tránh đánh giá thiên lệch/nhiều.

Câu 8. Giải thích lý do tại sao dữ liệu thiếu (missing data) làm giảm chất lượng của các mô hình học máy. Nêu hai phương pháp xử lý.

Đáp án:

- **Lý do giảm chất lượng:**
 - **Sai lệch hệ thống (Bias):** Dữ liệu thiếu thường mang thông tin quy luật, làm sai lệch phân phối thống kê.
 - **Lỗi thuật toán:** Gây gián đoạn các phép tính tích vô hướng $w^T x$ hoặc tính khoảng cách.
- **Phương pháp xử lý:**

1. **Loại bỏ (Removing):** Nhanh, đơn giản nhưng gây mất mát dữ liệu lớn và tăng Bias.
2. **Điền khuyết (Imputation):** Bảo toàn kích thước tập train, giảm bias nhưng có thể làm tăng Variance hoặc gây sai lệch nếu điền không chính xác.

Câu 9. Giải thích khái niệm Gradient Descent. Sự khác biệt giữa Batch Gradient Descent (BGD) và Stochastic Gradient Descent (SGD).

Đáp án:

- **Khái niệm:** Phương pháp tìm cực tiểu của hàm số bằng cách đi ngược hướng vector gradient để tối thiểu hóa hàm loss.
- **Cập nhật trọng số:** $w_{new} = w_{old} - \eta \cdot \nabla J(w)$ (với η là learning rate).
- **So sánh:**
 - **BGD:** Dùng toàn bộ dữ liệu để tính gradient. Quỹ đạo mượt, hướng trực tiếp tới đích nhưng chậm với dữ liệu lớn.
 - **SGD:** Dùng ngẫu nhiên 1 điểm dữ liệu để cập nhật ngay lập tức. Quỹ đạo nhiễu, ngoằn ngoèo nhưng nhanh và có khả năng thoát khỏi cực tiểu địa phương.

Câu 10. Mô tả cách hoạt động của thuật toán K-Nearest Neighbors (KNN) và cách chọn K.

Đáp án:

- **Cách hoạt động:** Tìm K điểm gần nhất với điểm cần dự đoán.
 - **Phân loại:** Dùng *majority voting* (đa số thắng thiểu số).
 - **Hồi quy:** Tính trung bình cộng các giá trị mục tiêu trong lân cận.
- **Cách chọn K:**
 - Nên chọn K lẻ để tránh trường hợp hòa nhau khi bỏ phiếu.
 - Dùng Cross-validation để thử các giá trị K khác nhau.
 - Quy tắc kinh nghiệm: $K = \sqrt{n}$.

Câu 11. Giải thích tại sao chuẩn hóa dữ liệu quan trọng, đặc biệt đối với các thuật toán dựa trên khoảng cách.

Đáp án:

- **Lý do:** Nếu không chuẩn hóa, các đặc trưng có biên độ lớn sẽ chi phối hoàn toàn hàm loss hoặc phép tính khoảng cách.
- **Thuật toán bị ảnh hưởng: KNN và K-Means.** Vì chúng dùng khoảng cách Euclid, nếu biến A có đơn vị hàng nghìn, biến B có đơn vị hàng đơn vị, thì biến B gần như không có đóng góp gì vào kết quả tính toán.

Câu 12. Bài toán dự đoán ung thư: TP=45, TN=100, FP=5, FN=10.

Đáp án:

- a) Tính các chỉ số:

$$- \text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN} = \frac{45+100}{45+100+5+10} = \frac{145}{160} \approx 90.6\%$$

$$- \text{Precision} = \frac{TP}{TP+FP} = \frac{45}{45+5} = \frac{45}{50} = 90\%$$

$$- \text{Recall} = \frac{TP}{TP+FN} = \frac{45}{45+10} = \frac{45}{55} \approx 81.8\%$$

$$- F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

- b) **Chỉ số nào quan trọng hơn?** Trong y tế (ung thư), **Recall** quan trọng hơn. Vì Recall liên quan đến FN (âm tính giả). Việc bỏ sót một người có bệnh (FN) nguy hiểm hơn nhiều so với việc chẩn đoán nhầm một người khỏe mạnh là có bệnh (FP) - trường hợp này có thể kiểm tra lại bằng các xét nghiệm chuyên sâu khác.